

Informe Final — Proyecto Integrador de Minería de Datos 1

Análisis de Usuarios de Plataforma de Streaming

Integrantes: [Nombre 1] — [Nombre 2] | Comisión: [Completar] | Fecha: [Completar]

1. Contexto y objetivo

El presente proyecto aplica los contenidos de Minería de Datos 1 sobre un dataset de usuarios de una plataforma de streaming latinoamericana. El objetivo es explorar patrones de consumo, documentar un proceso de limpieza justificado con evidencia, analizar relaciones entre variables y reducir dimensionalidad mediante PCA. El proyecto no incluye modelado predictivo.

2. Dataset y calidad inicial

El archivo *streaming_users_dirty.json* contiene 8.160 registros con 8 variables: *user_id*, *age*, *subscription_plan*, *monthly_watch_time_mins*, *country*, *favorite_genre*, *last_login_date* y *customer_support_tickets*. El dataset presentaba múltiples problemas de calidad: 753 nulos originales, 126 filas duplicadas, más de 55 variantes de texto en columnas categóricas, valores numéricos negativos e imposibles, y 535 fechas futuras en *last_login_date*.

3. Decisiones de limpieza y preparación

Se realizaron 9 pasos documentados en *logs/pipeline_log.csv* y desarrollados en *02_calidad_y_limpieza.ipynb*. Las decisiones principales fueron: (1) eliminación de 126 duplicados exactos; (2-4) normalización de *subscription_plan*, *country* y *favorite_genre* mediante diccionarios de mapeo basados en los valores únicos observados; (5) eliminación de edades fuera del rango [1, 100] por ser imposibles; (6) imputación de nulos en *monthly_watch_time_mins* con la mediana y eliminación de valores negativos y mayores a 5.000 min/mes; (7) eliminación de tickets de soporte negativos y mayores a 50; (8) anulación de fechas futuras en *last_login_date*; (9) eliminación de nulos residuales en columnas categóricas clave. La retención final fue del 89,2% (7.280 registros).

4. Hallazgos del análisis exploratorio

[Completar con los valores reales obtenidos al ejecutar *03_eda.ipynb*]. El análisis incluyó: distribución de edades de usuarios (UV-1), distribución del tiempo mensual de visualización (UV-2), comparación del tiempo promedio de visualización por plan de suscripción (BV-1), correlación entre tickets de soporte y tiempo de visualización (BV-2), y mapa de correlaciones entre variables numéricas (MV-1). Cada visualización se presenta con interpretación vinculada a los objetivos del proyecto en la aplicación Streamlit y en el notebook correspondiente.

5. Reducción de dimensionalidad — PCA

Se aplicó *StandardScaler* sobre las tres variables numéricas (*age*, *monthly_watch_time_mins*, *customer_support_tickets*) previo al PCA, dado que operan en escalas muy diferentes. [Completar con varianza explicada por componente y número de componentes necesarios para alcanzar el 80%]. Los loadings de cada componente se presentan en *04_pca.ipynb* con su interpretación. El biplot muestra la dirección de cada variable original en el espacio de las dos primeras componentes.

6. Conclusiones y limitaciones

[Completar con hallazgos reales al ejecutar]. Limitaciones: el dataset no incluye información de contenido consumido ni fecha de alta del usuario; las fechas inválidas eliminadas podrían representar un sesgo sistemático no identificable con la información disponible.

Repositorio: [https://github.com/\[usuario\]/PI_Mineria_Datos_1](https://github.com/[usuario]/PI_Mineria_Datos_1) | Streamlit: [https://\[app\].streamlit.app](https://[app].streamlit.app)