

Análisis de Usuarios de Plataforma de Streaming

Proyecto Integrador — Minería de Datos 1 | Turno Tarde, Nodo | Achával María José | 06/07/2026

1. Contexto y objetivo

El proyecto aplica los contenidos de Minería de Datos 1 sobre un dataset de usuarios de una plataforma de streaming latinoamericana. El objetivo es explorar patrones de consumo, identificar y corregir problemas de calidad de datos, preparar el dataset con decisiones justificadas y aplicar reducción de dimensionalidad mediante PCA. El análisis responde a cinco preguntas definidas en la etapa de inspección inicial.

2. Dataset y calidad inicial

El archivo *streaming_users_dirty.json* contiene 8.160 registros de usuarios con 8 variables: *user_id*, *age*, *subscription_plan*, *monthly_watch_time_mins*, *country*, *favorite_genre*, *last_login_date* y *customer_support_tickets*. El dataset presentaba problemas intencionales: 160 filas duplicadas, 753 valores nulos, 296 valores numéricos imposibles, 55+ variantes de texto inconsistentes en variables categóricas y 528 fechas futuras en *last_login_date*.

3. Decisiones de limpieza y preparación

Se realizaron 7 pasos documentados en *logs/pipeline_log.csv*: eliminación de 160 duplicados exactos y por *user_id*; normalización de *subscription_plan*, *country* y *favorite_genre* a sus categorías canónicas; conversión a NaN de valores imposibles en *age* (<13 o >100), *monthly_watch_time_mins* (negativos o ≥ 10.000) y *customer_support_tickets* (negativos o atípicos); winsorización de *monthly_watch_time_mins* con límite $Q3+3\cdot IQR$ (≈ 2.692 min); anulación de fechas futuras en *last_login_date* sin imputación; e imputación de *age* y *monthly_watch_time_mins* con mediana agrupada por plan (mecanismo MAR). La retención final fue del 98,0% (8.000 de 8.160 filas).

4. Hallazgos del análisis exploratorio

Visualización	Hallazgo principal
UV-1: Distribución de edades	Concentrada entre 25 y 45 años. Media $\approx 33,6$ / Mediana $\approx 33,0$.
UV-2: Tiempo de visualización	Distribución asimétrica. Media ≈ 790 min/mes, Mediana ≈ 771 min/mes.
BV-1: Plan vs. watch time	Básico ≈ 587 , Estándar ≈ 862 , Premium ≈ 1.123 min/mes.
BV-2: Tickets vs. watch time	Correlación $r \approx 0,003$. Sin relación lineal.
MV-2: País y plan vs. watch time	Patrón Premium > Estándar > Básico consistente en los 7 países.

5. Reducción de dimensionalidad — PCA

Se aplicó PCA sobre las tres variables numéricas (*age*, *monthly_watch_time_mins*, *customer_support_tickets*) previo escalamiento con *StandardScaler*. La varianza se distribuyó de forma casi uniforme: PC1 $\approx 33,8\%$, PC2 $\approx 33,2\%$, PC3 $\approx 33,0\%$. Se requieren las 3 componentes para superar el 80% de varianza acumulada, confirmando que las variables son estadísticamente independientes. PC1 combina edad y consumo (compromiso general); PC2 contrapone edad y consumo; PC3 está dominada por tickets de soporte. El PCA aporta valor interpretativo, no de compresión de dimensionalidad.

6. Conclusiones y limitaciones

Hallazgo 1: El plan de suscripción es el principal diferenciador del consumo. Los usuarios Premium consumen casi el doble que los Básicos (≈ 1.123 vs. ≈ 587 min/mes), patrón consistente en todos los países analizados.

Hallazgo 2: Las tres variables numéricas son estadísticamente independientes entre sí ($r < 0,01$ en todos los pares), sin multicolinealidad.

Hallazgo 3: Los tickets de soporte no se asocian con menor consumo ($r \approx 0,003$), por lo que no deben usarse como proxy aislado de insatisfacción.

Limitaciones: El alcance de las conclusiones está condicionado por la información disponible y las decisiones documentadas durante el proceso. La naturaleza sintética del dataset limita la generalización a datos reales.

Repositorio: github.com/MajoAchaval/PI_Mineria_Datos_1 | Aplicación: pi-mineriadatos1.streamlit.app