

Análisis de Usuarios de Plataforma de Streaming

Proyecto Integrador — Minería de Datos 1 | Turno Tarde, Nodo | Achával María José | 06/07/2026

1. Contexto y objetivo

El proyecto aplica los contenidos de Minería de Datos 1 sobre un dataset de usuarios de una plataforma de streaming latinoamericana. El objetivo es construir un análisis reproducible que permita explorar patrones de consumo, identificar y corregir problemas de calidad de datos, preparar el dataset con decisiones justificadas y aplicar reducción de dimensionalidad mediante PCA. El análisis responde a cinco preguntas definidas en la etapa de inspección inicial.

2. Dataset y calidad inicial

El archivo `streaming_users_dirty.json` contiene 8.160 registros con 8 variables: `user_id`, `age`, `subscription_plan`, `monthly_watch_time_mins`, `country`, `favorite_genre`, `last_login_date` y `customer_support_tickets`. Presentaba: 160 filas duplicadas, 753 valores nulos, 296 valores numéricos imposibles, 55+ variantes de texto inconsistentes y 528 fechas futuras en `last_login_date`.

3. Decisiones de limpieza y preparación

Se realizaron 7 pasos documentados en `logs/pipeline_log.csv`: eliminación de 160 duplicados; normalización de variables categóricas a sus valores canónicos; conversión a NaN de valores imposibles en `age`, `monthly_watch_time_mins` y `customer_support_tickets`; winsorización con límite $Q3+3\cdot IQR$ (≈ 2.692 min); anulación de fechas futuras sin imputación; e imputación con mediana agrupada por plan (mecanismo MAR confirmado). Retención final: 98,0% (8.000 de 8.160 filas).

4. Hallazgos del análisis exploratorio

Visualización	Hallazgo principal
Distribución de edades	Concentrada entre 25 y 45 años. Media $\approx 33,6$ / Mediana $\approx 33,0$. Distribución simétrica.
Género favorito	Drama, Acción y Comedia concentran las preferencias en los 7 países analizados.
Plan vs. watch time	Básico ≈ 587 , Estándar ≈ 862 , Premium ≈ 1.123 min/mes. Relación escalonada y consistente.
Tickets vs. watch time	Correlación $r \approx 0,003$. El consumo se mantiene estable sin importar los tickets generados.
País y plan vs. watch time	Patrón Premium > Estándar > Básico consistente en todos los países. Sin variación geográfica.

5. Reducción de dimensionalidad — PCA

Se aplicó PCA sobre `age`, `monthly_watch_time_mins` y `customer_support_tickets` previo escalamiento con `StandardScaler`. La varianza se distribuyó de forma casi uniforme: $PC1 \approx 33,8\%$, $PC2 \approx 33,2\%$, $PC3 \approx 33,0\%$, requiriendo las 3 componentes para superar el 80% acumulado. $PC1$ representa un perfil de usuario activo general (`age`: 0,646; `watch_time`: 0,554; `tickets`: 0,525); $PC2$ contrapone tickets (0,749) y consumo ($-0,661$); $PC3$ está dominada por la edad (0,762). El PCA aporta valor interpretativo, no de compresión de dimensionalidad.

6. Conclusiones y limitaciones

Hallazgo 1 — El plan define el nivel de consumo: Los usuarios Premium consumen casi el doble que los Básicos (≈ 1.123 vs. ≈ 587 min/mes). Este patrón es consistente en los 7 países y convierte al plan en el

principal segmentador del comportamiento de uso.

Hallazgo 2 — Perfil demográfico adulto joven: La base de usuarios se concentra entre los 25 y 45 años (media $\approx$ 33,6, mediana $\approx$ 33,0), sin sesgo marcado hacia usuarios muy jóvenes ni muy mayores.

Hallazgo 3 — Cobertura regional equilibrada: Los 7 países tienen representación similar, sin un mercado dominante. Drama, Acción y Comedia concentran las preferencias de contenido en toda la región.

Hallazgo 4 — Las variables numéricas son independientes entre sí: Correlaciones de Pearson prácticamente nulas ($r < 0,01$ en todos los pares), confirmado por el PCA. Cada variable aporta información distinta sobre el usuario.

Hallazgo 5 — Los tickets no predicen el consumo: La correlación entre tickets de soporte y tiempo de visualización es $r \approx 0,003$. Los tickets no deben usarse como proxy aislado de insatisfacción o riesgo de abandono.

Limitaciones: El alcance está condicionado por la información disponible y las decisiones documentadas durante el proceso. El dataset no incluye información sobre si un usuario abandonó el servicio ni sobre el contenido consumido. La naturaleza sintética limita la generalización a datos reales.

Repositorio: github.com/MajoAchaval/PI_Mineria_Datos_1 | Aplicación: pi-mineriadatos1.streamlit.app